

회귀 분석 실습 개념 정리

주문 금액 예측 실습(9장)에서 나온 개념을, 한글 이름 (영어 이름) 순서로 정리한 학습 자료

이 실습을 한 문장으로

주문이 들어올 때 그 주문의 금액을 미리 맞힐 수 있는지, 모델을 만들고 **공정하게 시험**해 본 실습입니다. 결과는 "지금 가진 정보로는 맞히기 어렵다"였고, 그 결론을 믿을 수 있게 만든 과정이 핵심입니다.

1. 전체 흐름 한눈에 보기

시험에 비유하면 이해하기 쉽습니다. 학생(모델)에게 문제집으로 공부시키고, 시험을 쳐서 실력을 확인하는 과정입니다.

단계	하는 일	시험 비유
문제 정의	주문 1건의 금액을 맞히는 문제로 정함	무엇을 맞히는 시험인지 정하기
특성 점검	예측에 써도 되는 정보만 고름	시험 때 볼 수 있는 자료만 허용
시간 순서 분리	과거 주문으로 공부, 가장 최근 기간으로 시험	작년 기출로 공부하고 올해 시험 치르기
전처리	빈칸 채우기, 숫자 크기 맞추기, 글자를 숫자로 바꾸기	시험지 양식 통일하기
후보 모델 준비	평균 예측, 선형 회귀, 랜덤 포레스트	찍기 학생 1명, 공부한 학생 2명
교차검증	공부 기간 안에서 모의고사를 5번 봄	정식 시험 전 모의고사
모델 선택 고정	모의고사 결과로 대표 모델을 미리 정함	정식 시험 전에 대표 확정
최종 시험	평균 예측과 대표 모델만 정식 시험 (딱 한 번)	정식 시험
해석과 판단	점수의 의미 읽기, 큰 오차 살펴보기, 사용 여부 결정	오답 노트, 채용 여부 결정

2. 기본 개념: 모델과 예측

머신러닝 (Machine Learning)

사람이 규칙을 일일이 정해 주는 대신, **데이터를 보여 주고 컴퓨터가 규칙을 스스로 찾게 하는 방법**입니다. 인공지능 (Artificial Intelligence, AI)의 한 분야입니다.

모델 (Model)

데이터에서 찾아낸 규칙을 담은 결과물입니다. 정보를 넣으면 예측값을 내놓는 **계산 기계**라고 생각하면 됩니다. 이번 실습의 선형 회귀와 랜덤 포레스트가 모두 모델입니다.

학습 (Training / fit)과 예측 (Prediction / predict)

학습은 모델이 과거 데이터에서 규칙을 익히는 과정이고, **예측**은 학습한 규칙으로 새 데이터의 답을 추정하는 과정입니다. 코드에서는 각각 `fit()`과 `predict()`로 씁니다.

회귀 (Regression)와 분류 (Classification)

구분	맞히는 것	예시
회귀	숫자를 예측	주문 금액, 집값, 다음 달 매출
분류	종류(범주)를 예측	스팸 여부, 고객 이탈 여부

이번 실습은 주문 금액이라는 숫자를 맞히므로 **회귀 문제**입니다. "회귀 모델"은 숫자를 예측하는 모델을 통칭하는 말입니다.

목표값 (Target)과 특성 (Feature)

용어	뜻	이번 실습
목표값 (Target)	맞히고 싶은 정답	주문 금액 (order_total)
특성 (Feature)	정답을 맞히기 위해 쓰는 정보(단서)	주문 월, 요일, 결제수단, 나이, 성별, 도시 (6개)

모델 예측과 평균 예측 (Baseline) ★ 가장 중요한 비교

구분	모델 예측	평균 예측 (Baseline)
하는 일	주문 조건(월, 요일, 나이 등)에 따라 주문마다 다른 값 을 냄	모든 주문에 같은 값 (과거 평균 금액)을 냄
영어 이름	Linear Regression, Random Forest 등	Baseline, DummyRegressor(strategy="mean")
역할	패턴을 찾으려는 시도	비교 기준선 . 못하는 모델이 아님

왜 평균 예측과 비교할까? 복잡한 모델이 "그냥 평균을 말하는 것"보다 나아야 만든 의미가 있기 때문입니다. 모델이 복잡하다는 사실만으로는 좋다고 말할 수 없고, 실제 검증 결과로만 판단합니다.

비유: 내일 기온을 맞히는데 "매일 평년 기온을 말하는 사람"이 있다고 합시다. 공부한 예보관이 이 사람보다 못 맞힌다면 예보관을 쓸 이유가 없습니다.

이번 실습의 후보 모델 3개

모델	설명
평균 예측 (Baseline Mean)	항상 학습 데이터의 평균 금액만 말함. 기준선.
선형 회귀 (Linear Regression)	"나이가 1살 늘면 금액이 얼마 변한다"처럼 직선 관계 로 예측하는 단순한 모델.
랜덤 포레스트 (Random Forest)	"조건이 A면 왼쪽, B면 오른쪽" 같은 질문 나무(결정 트리)를 수백 개 만들어 평균내는 복잡한 모델. 직선이 아닌 관계도 잡을 수 있지만 잡음까지 외우기 쉬움.

3. 데이터 준비 개념

데이터 누수 (Data Leakage) ★ 이번 실습의 핵심 원칙

예측하는 시점에는 알 수 없는 정보(또는 정답을 계산하는 재료)가 모델 입력에 섞이는 것입니다. 시험 문제의 답을 미리 보고 푸는 것과 같아서, 점수는 높게 나오지만 실제로는 쓸 수 없는 모델이 됩니다.

구분	예시	처리
정답 계산 재료	수량(quantity), 단가(unit_price), 금액(line_total)	제외 (주문 금액 = 수량 × 단가의 합)
사후 정보	주문 상태(order_status: 완료, 취소, 환불)	제외 (주문이 끝난 뒤에 정해짐)
식별자 (ID)	주문번호, 고객번호, 상품번호	제외 (의미 없는 번호)
주문 상세 정보	상품 카테고리, 상품명	제외 (무엇을 담을지는 예측 시점에 모름)

판단 기준은 "예측 시점에 알 수 있는가?"입니다. 상관계수가 높은지 낮은지가 기준이 아닙니다. 단가는 정답과의 상관계수가 낮아도 정답을 계산하는 재료라서 제외합니다.

예측 시점 (Prediction Time)

"언제 이 예측을 하는가?"를 정하는 것입니다. 이번에는 **주문이 들어오는 순간**으로 정했고, 이 시점에 알 수 있는 정보(월, 요일, 결제수단, 고객 나이, 성별, 도시)만 특성으로 썼습니다.

상관계수 (Correlation Coefficient)

두 값이 얼마나 함께 움직이는지 나타내는 숫자(-1 ~ 1)입니다. 0에 가까우면 관계가 거의 없다는 뜻입니다. 이번 실습에서 사용한 특성의 상관계수는 나이 -0.03, 주문 월 0.05 정도로 **주문 금액과 거의 무관**했습니다.

결측치 (Missing Value)와 대체 (Imputation)

비어 있는 값을 결측치라 하고, 이를 다른 값으로 채우는 것을 대체라 합니다.

- 숫자형: **중앙값 대체** (median imputation) — 값을 크기순으로 세웠을 때 가운데 값으로 채움
- 범주형(글자): **최빈값 대체** (most_frequent imputation) — 가장 많이 나온 값으로 채움

이번 데이터에는 결측치가 0개였지만, 새 데이터에 생길 때를 대비해 파이프라인에 넣어 둡니다.

표준화 (Standardization / StandardScaler)

숫자들의 크기를 맞추는 작업입니다. 평균을 0, 흩어진 정도(표준편차)를 1로 바꿉니다. 나이(19~69)와 요일(0~6)처럼 단위가 다른 숫자를 공평하게 비교하기 위해 씁니다.

원-핫 인코딩 (One-Hot Encoding)

"서울, 부산" 같은 글자를 컴퓨터가 이해하는 **0과 1의 칸**으로 바꾸는 방법입니다. 예를 들어 도시가 서울이면 "도시_서울" 칸만 1이고 나머지 칸은 0입니다. 이번 실습에서 글자 특성 3개(결제수단 4종, 성별 2종, 도시 10종)가 **16개 칸**으로 늘어나 숫자형 3개와 합쳐 총 19개 컬럼이 되었습니다. 학습 때 못 본 값이 나와도 오류 없이 모두 0으로 처리하도록 `handle_unknown="ignore"`를 씁니다.

파이프라인 (Pipeline)과 fit / transform

전처리와 모델을 **하나의 줄(순서)로 묶은 것**입니다. 핵심 규칙은 다음과 같습니다.

- **fit**: 기준을 배움 (평균, 중앙값, 범주 목록 등) — **학습 데이터에서만**
- **transform**: 배운 기준을 적용만 함 — 학습 데이터와 시험 데이터 모두에

전체 데이터로 먼저 fit하면 안 되는 이유: 시험 데이터의 평균 같은 정보가 전처리에 섞여 들어가서, 시험 문제를 미리 보는 것과 같은 누수가 생깁니다. 파이프라인을 쓰면 이 실수를 자동으로 막아 줍니다. 그래서 교차검증 때도 매번 그 학습 구간에서만 fit합니다.

4. 데이터 나누기와 검증 개념

학습 데이터 (Train)와 최종 시험 데이터 (Final Test)

구분	역할	이번 실습
Train	모델이 공부하는 데이터	2025-09-11 ~ 2026-06-10 (239건)
Final Test	공부가 끝난 뒤 딱 한 번 보는 정식 시험	2026-06-11 ~ 2026-09-10 (61건)

비율은 약 80% 대 20%입니다. Train이 너무 적으면 배울 재료가 부족하고, Test가 너무 적으면 시험 문제가 몇 개 안 돼서 점수를 믿기 어렵습니다.

시간 순서 분할 (Chronological / Time-based Split)과 랜덤 분할 (Random Split)

구분	방식	문제점
랜덤 분할	주문을 무작위로 섞어서 나눔	미래 주문이 학습 데이터에 섞여 미래를 미리 보고 공부 하게 됨
시간 순서 분할	과거는 Train, 가장 최근은 Final Test	실제 사용 상황(과거로 미래 예측)과 같아 공정함

핵심 조건은 **Train의 마지막 날짜 < Final Test의 첫 날짜**이며, 같은 날짜가 양쪽에 동시에 들어가면 안 됩니다.

교차검증 (Cross-Validation, CV)과 TimeSeriesSplit

정식 시험 전에, 학습 데이터 안에서 모의고사를 여러 번 보는 것입니다. 시간이 있는 데이터는 시계열 교차검증 (TimeSeriesSplit)을 씁니다. 과거로 공부하고 그 바로 다음 기간으로 시험 보는 방식을 반복하며, 시험 구간이 항상 공부 구간보다 뒤에 옵니다.

모의고사(Fold) 번호	1	2	3	4	5
공부한 건수	44	83	122	161	200
시험 본 건수	39	39	39	39	39

Fold(폴드)는 교차검증에서 나눈 한 조각(한 번의 모의고사)을 뜻합니다.

모델 선택 고정 (Freezing the Selected Model)

모의고사(교차검증) 결과로 대표 모델을 미리 정하고 바꾸지 않는 것입니다. 정식 시험(Final Test) 결과를 보고 잘 나온 모델로 바꾸면 Final Test가 모델 선택에 참여하게 되어 공정성이 깨집니다.

과적합 (Overfitting)

학습 데이터의 우연한 패턴까지 외워서, 학습 데이터 점수는 좋은데 새 데이터에서는 못 맞히는 현상입니다. 기출문제 답만 외운 학생이 새 문제를 못 푸는 것과 같습니다. 이번 랜덤 포레스트가 그랬습니다. 학습 오차는 약 17만인데 시험 오차는 약 50만으로 3배 가까이 벌어졌습니다.

재현성 (Reproducibility)과 random_state

같은 코드를 다시 돌렸을 때 같은 결과가 나오는 성질입니다. 랜덤 포레스트처럼 무작위 요소가 있는 모델은 random_state=42로 고정해야 매번 같은 결과가 나옵니다. 그래서 커널을 재시작하고 처음부터 다시 실행 (Restart and Run All)해도 같은 숫자가 나와야 합니다.

5. 평가지표 (Evaluation Metrics)

오차 (Error)와 잔차 (Residual)

예측이 실제와 얼마나 다른지를 뜻합니다. 실습에서는 다음과 같이 정의합니다.

잔차 (residual) = 실제값 - 예측값

절대 오차 (abs_error) = |잔차|

- 잔차가 양수(+)면 실제보다 낮게 예측한 것, 음수(-)면 실제보다 높게 예측한 것입니다.
- 예: 실제 300만 원인데 80만 원으로 예측하면 잔차는 +220만, 절대 오차는 220만입니다.

MAE (Mean Absolute Error, 평균 절대 오차)

MAE = 절대 오차들의 평균

평균적으로 몇 원 정도 틀리는가를 그대로 보여 줍니다. 금액과 같은 단위(원)로 읽을 수 있어 이해하기 쉽고, 작을수록 좋습니다.

RMSE (Root Mean Squared Error, 평균 제곱근 오차)

RMSE = 오차를 제곱해서 평균낸 값의 제곱근

MAE와 비슷하지만 **큰 오차에 더 민감**합니다. RMSE가 MAE보다 **훨씬 크면** 일부 주문에서 크게 틀리고 있다는 신호입니다. 이번 실습은 RMSE가 MAE의 약 1.17배로, 큰 오차가 몇 개 몰려 있기보다 **전반적으로 넓게 틀리는** 경우였습니다.

R² (R-squared, 결정계수)

모델이 "**평균 예측**"보다 얼마나 더 잘 맞히는가를 나타냅니다.

R ² 값	의미
1에 가까움	변동을 잘 설명함 (높은 설명력)
0 근처	평균 예측과 비슷한 수준
0보다 작음 (음수)	평균 예측보다 못함

R²가 음수라고 해서 코드 오류는 아닙니다. 모델이 평균 예측보다 못하다는 정직한 결과일 수 있습니다.

표준편차 (Standard Deviation, std)와 안정성

값이 얼마나 **흔들리는지** 나타냅니다. 교차검증에서 모의고사마다 점수가 크게 다르면 표준편차가 큼니다. 평균이 괜찮아도 표준편차가 크면 **결과를 믿기 어렵습니다**. 그래서 평균과 표준편차를 함께 봅니다.

개선율 (MAE improvement vs baseline)

개선율(%) = (Baseline의 MAE - 모델의 MAE) ÷ Baseline의 MAE × 100

양수면 평균 예측보다 좋고, 음수면 **평균 예측보다 나쁩니다**.

6. 이번 실습 결과 읽기

교차검증(모의고사) 결과 — 학습 기간

모델	MAE 평균	MAE 표준편차	R ² 평균	평가
평균 예측 (Baseline)	420,959	45,361	-0.026	가장 좋음, 가장 안정적
선형 회귀	470,981	74,273	-0.384	평균 예측보다 나쁨, 가장 불안정
랜덤 포레스트	469,067	53,894	-0.349	평균 예측보다 나쁨

선택 규칙에 따라 두 모델 중 MAE 평균이 더 낮은 **랜덤 포레스트**를 대표로 고정했습니다. 다만 두 모델의 차이(약 1,900)는 표준편차(5만~7만)보다 훨씬 작아서 **사실상 차이가 없습니다**.

최종 시험(Final Test) 결과

모델	Train MAE	Test MAE	Test RMSE	Test R ²	개선율
평균 예측 (Baseline)	414,435	448,808	526,649	-0.002	0.0%
랜덤 포레스트 (고정 모델)	167,643	497,946	580,811	-0.219	-10.9%

읽는 법

- **MAE:** 평균 예측은 평균 약 45만, 랜덤 포레스트는 약 50만 틀립니다. 랜덤 포레스트가 약 11% 더 틀립니다. (Final Test 기간의 평균 주문 금액은 약 83만이어서, 평균 예측오차 금액의 절반 이상을 틀립니다.)
- **RMSE:** 여기서도 평균 예측이 앞섭니다.
- **R²:** 랜덤 포레스트는 -0.219로, 평균 예측보다 못합니다.
- **과적합:** 랜덤 포레스트의 Train MAE(약 17만)와 Test MAE(약 50만)가 3배 가까이 차이 납니다.
- **일관성:** 모의고사에서 약 11% 나빴던 것이 정식 시험에서도 약 11% 나빴습니다. 우연이 아니라 **특성의 예측력이 약해서** 나온 결과로 볼 수 있습니다.

7. 결과 해석과 최종 판단

왜 이런 결과가 나왔을까?

- 주문 금액은 **무엇을 몇 개 담았는가**(수량 × 단가)에 달려 있는데, 이 정보는 주문 전에는 알 수 없어서 **데이터 누수를 막기 위해 제외**했습니다.
- 남은 특성(월, 요일, 결제수단, 나이, 성별, 도시)은 주문 금액과 거의 관계가 없어서 모델이 맞힐 단서가 부족했습니다.
- 관계가 없는 특성으로 복잡한 모델을 학습시키면 우연한 패턴을 외우게 되어 오히려 평균 예측보다 나빠집니다.

성능이 낮으면 실패일까요? 아닙니다. 수량과 단가를 특성에 넣으면 점수는 매우 좋아지지만, 그건 정답을 미리 보고 푸는 **누수**라서 실제로 쓸 수 없는 모델이 됩니다. 누수를 막고 정직하게 검증했더니 "이 문제는 지금 정보로는 어렵다"는 답이 나온 것이고, 이것도 훌륭한 분석 결과입니다.

최종 사용 판단: 세 가지 선택지

선택지	이번 판단
현재 수준에서 참고용으로 사용 가능	해당 없음
추가 검증 후 사용 가능	해당 없음
현재 데이터로는 사용 보류	선택 — 평균 예측보다 나은 점이 없고, 오차가 평균 금액의 절반 이상이라 업무에 쓰기 어려움

하지 말아야 할 행동 (낮은 성능을 숨기려는 행동)

- 정답 계산 재료(수량, 단가 등)를 특성에 추가하기
- 사후 정보(주문 상태 등)를 특성에 추가하기

- Final Test에서 가장 잘 나온 모델로 바꾸기
- 같은 Final Test를 반복해서 모델을 고르는 데 쓰기

다음 개선 방향 (가능성이며 검증이 필요함)

- 예측 시점에 알 수 있으면서 금액과 관계가 있는 정보가 있는지 찾아보기 (예: 고객의 과거 평균 주문 금액)
- 더 많은 기간의 데이터를 확보하기 (지금은 Train에 7~8월이 없고 Final Test가 61건뿐)
- 추가 실험은 새로운 검증 설계 또는 새로운 미래 평가 구간이 필요함 (지금의 Final Test를 다시 쓰면 안 됨)

8. 자주 헷갈리는 질문

Q1. "모델 예측"과 "평균 예측" 중 어떤 것이 더 의미 있나요?

개념적으로는 **모델 예측**이 의미가 큼니다. 주문마다 다른 값을 내며 패턴을 찾으려는 시도이기 때문입니다. 하지만 이번 결과에서는 그 시도가 성공하지 못해서, **실제로 더 믿을 만한 것은 평균 예측**입니다. 두 예측을 나란히 비교했기 때문에 이 사실을 알 수 있었습니다.

Q2. 제가 인공지능 모델을 만든 건가요?

네, 데이터에서 규칙을 학습하는 **머신러닝 모델**을 만들었습니다. 다만 ChatGPT나 Claude 같은 대규모 언어 모델 (LLM)과는 다른 종류이고, 이번 모델은 성능이 낮아 실제 업무에는 쓰지 않습니다. 이 실습의 초점은 모델을 만드는 것보다 **제대로 검증하는 방법**을 익히는 것입니다.

Q3. 이 모델로 실제 예측을 할 수 있나요?

기술적으로는 가능합니다. 학습 때 쓴 6개 컬럼과 같은 이름의 표를 만들어 `predict()`에 넣으면 금액을 내놓습니다. 다만 정확도가 낮아서 **예측값을 업무에 쓰면 안 됩니다**.

Q4. 검증이 모두 통과(PASS)면 좋은 모델인가요?

아닙니다. 자동 검증은 **규칙을 지켰는지**(금지 특성 없음, 시간 순서 지킴, 고정 모델이 Final Test에 들어감 등)만 확인하고, 성능이 좋은지는 판단하지 않습니다. 모두 PASS이면서 성능이 낮은 것이 이번 결과입니다. "결과를 믿을 수 있다"는 뜻입니다.

Q5. 왜 개인 식별 정보를 나눠서 관리하나요?

주문번호나 고객번호가 든 파일(내부 진단 파일)은 개별 고객을 알아볼 수 있어서 **내부용으로만** 두고, 공개 보고서에는 식별자를 제거한 요약만 담습니다. "모델이 잘 만들어졌는가"와 "결과를 공개해도 되는가"는 별개의 검토입니다.

9. 용어 빠른 찾기

한글 (English)	한 줄 뜻
머신러닝 (Machine Learning)	데이터에서 컴퓨터가 규칙을 스스로 찾는 방법
모델 (Model)	규칙을 담은 예측 기계
학습 (Training, fit)	모델이 과거 데이터에서 규칙을 익힘
예측 (Prediction, predict)	학습한 규칙으로 새 데이터의 답을 추정

회귀 (Regression)	숫자를 예측하는 문제
분류 (Classification)	종류를 예측하는 문제
목표값 (Target)	맞히고 싶은 정답 (주문 금액)
특성 (Feature)	정답을 맞추기 위한 단서 (월, 요일, 나이 등)
평균 예측 (Baseline)	항상 평균만 말하는 비교 기준
선형 회귀 (Linear Regression)	직선 관계로 예측하는 단순 모델
랜덤 포레스트 (Random Forest)	결정 트리 여러 개를 평균내는 복잡한 모델
데이터 누수 (Data Leakage)	예측 시점에 모르는 정보가 입력에 섞이는 것
예측 시점 (Prediction Time)	예측을 하는 순간
결측치 (Missing Value)	비어 있는 값
대체 (Imputation)	빈 값을 다른 값으로 채움
표준화 (Standardization)	숫자 크기를 맞춤 (평균 0, 표준편차 1)
원-핫 인코딩 (One-Hot Encoding)	글자를 0과 1의 칸으로 바꿈
파이프라인 (Pipeline)	전처리와 모델을 하나로 묶은 것
학습 데이터 (Train)	모델이 공부하는 데이터
최종 시험 데이터 (Final Test)	딱 한 번 보는 정식 시험 데이터
시간 순서 분할 (Chronological Split)	과거는 공부, 최근은 시험으로 나눔
교차검증 (Cross-Validation, CV)	학습 데이터 안에서 모의고사를 여러 번 봄
과적합 (Overfitting)	학습 데이터만 외워 새 데이터에 약함
재현성 (Reproducibility)	다시 실행해도 같은 결과가 나옴
잔차 (Residual)	실제값 - 예측값
MAE (평균 절대 오차)	평균적으로 얼마나 틀리는가, 작을수록 좋음
RMSE (평균 제곱근 오차)	큰 오차에 민감한 오차 지표
R ² (결정계수)	평균 예측 대비 설명력, 음수면 평균보다 못함
표준편차 (Standard Deviation)	값이 흔들리는 정도

※ 이 자료의 숫자는 이번 실습(주문 300건, 2025-09 ~ 2026-09)에서 나온 결과입니다. 금액 단위는 데이터에 표기가 없어 원 단위로 가 정했습니다.